

EDUPREDICT

Analyse des facteurs associés à la performance scolaire

RAPPORT COMPLET - ÉVALUATION 2 SPRINT PRODUIT EN SQUAD

Question métier

Quels facteurs observables dans les données sont associés aux performances des élèves aux examens, et comment ces informations peuvent-elles aider un établissement à mieux identifier les besoins d'accompagnement scolaire ?

Élément	Information
Domaine	Éducation / Data Analytics
Dataset	Students' Performance in Exams
Volume	1 000 élèves - 8 variables
Période du sprint	1er au 5 octobre 2026
Livrable	Notebook analytique + rapport + prototype

Sommaire

1. Résumé exécutif
2. Contexte, problème et objectifs
3. Équipe et organisation
4. Données et périmètre analytique
5. Méthodologie
6. Contrôle qualité et préparation des données
7. Résultats descriptifs
8. Analyses comparatives
9. Corrélations entre les matières
10. Catégories de performance
11. Interprétation métier
13. Recommandations opérationnelles
14. Limites et risques d'interprétation
15. Évaluation de l'atteinte des objectifs
16. Conclusion

1. Résumé exécutif

EduPredict vise à comprendre les associations observables entre certaines caractéristiques des élèves et leurs performances aux examens. Le projet répond à une question orientée décision : comment mieux repérer les besoins d'accompagnement scolaire à partir de données simples et disponibles ? La proposition initiale fixe comme périmètre l'exploration, la comparaison des groupes, la visualisation, la production d'indicateurs et la formulation de recommandations fondées sur les données.

Résultat central

Dans les données analysées, la préparation aux examens présente l'association la plus directement exploitable parmi les facteurs comparés : les élèves ayant terminé le cours de préparation obtiennent un score moyen de 72,67 contre 65,04 pour ceux qui ne l'ont pas suivi, soit un écart de 7,63 points. Cette différence est descriptive et ne démontre pas un effet causal.

Indicateur clé	Résultat
Élèves analysés	1 000
Score moyen global	67,77 / 100
Médiane du score moyen	68,33 / 100
Catégorie Faible	285 élèves (28,5 %)
Catégorie Moyenne	391 élèves (39,1 %)
Catégorie Bonne	324 élèves (32,4 %)
Préparation - completed	72,67
Préparation - none	65,04

Message décisionnel : les données soutiennent surtout l'idée d'un dispositif de repérage et d'accompagnement, et non la création d'un système de décision automatique. Le prototype obtient une performance limitée sur un jeu de test de 200 élèves et doit donc rester pédagogique.

2. Contexte, problème et objectifs

La proposition de projet part du constat que les établissements disposent de résultats d'évaluation mais rencontrent des difficultés pour identifier rapidement les facteurs associés aux écarts de performance. EduPredict cherche donc à transformer les données scolaires en informations interprétables et potentiellement utiles à l'accompagnement des élèves.

2.1 Problème métier

Le problème n'est pas de prédire parfaitement la réussite, mais de comprendre quels facteurs observables sont associés aux différences de résultats et comment ces observations peuvent soutenir des actions éducatives.

2.2 Objectifs retenus

1. Explorer les performances scolaires.
2. Identifier les principaux facteurs associés aux résultats.
3. Comparer les performances entre différents groupes.

4. Visualiser les résultats sous forme de graphiques.
5. Produire des indicateurs simples d'aide à la décision.
6. Formuler des recommandations fondées sur les données.

Cadre d'interprétation

La proposition précise que le projet ne cherche pas à établir une causalité : les résultats sont présentés comme des associations observées dans le dataset.

3. Équipe et organisation

La Squad fonctionne selon une logique collaborative : chaque membre porte une responsabilité principale, mais les décisions importantes sont prises collectivement.

Membre	Rôle	Contribution principale
Nkondi Mbouyou David Prince	Product Manager / Coordination	Vision du projet, coordination, priorisation, cohérence des livrables, préparation finale
Koubatika Elsy Fernandez	Data Analyst / Responsable Notebook	Importation, exploration, nettoyage, analyses statistiques, notebook, interprétation
Makaya Sita Paterli Emmanuel	Data Analyst / Visualisation	Graphiques, comparaisons, tendances, visuels du rapport
Mologbama Ndoanayahveh Abishadaï Malkiyeshoua	Business Analyst / Documentation	Questions analytiques, besoins métier, interprétation, documentation
Kolela Henriety Evans Fernandel	Digital Marketing / Présentation	Positionnement, communication, messages simples, présentation

4. Données et périmètre analytique

Le notebook utilise le dataset Students' Performance in Exams, composé de 1 000 observations et de 8 variables. Le périmètre initial couvre le genre, le groupe ethnique indiqué, le niveau d'éducation des parents, le type de repas, la préparation aux examens et trois scores scolaires : mathématiques, lecture et écriture.

Variable	Nature	Usage
gender	Catégorielle	Comparaison des scores moyens
race/ethnicity	Catégorielle	Variable explicative candidate
parental level of education	Catégorielle	Comparaison des scores moyens
lunch	Catégorielle	Comparaison des scores moyens
test preparation course	Catégorielle	Facteur de comparaison prioritaire
math score	Numérique	Performance par matière
reading score	Numérique	Performance par matière
writing score	Numérique	Performance par matière

5. Méthodologie

Le notebook suit une chaîne analytique complète : chargement, contrôle de structure, nettoyage, création d'un indicateur synthétique, analyses descriptives, comparaisons de groupes, corrélations, catégorisation de la performance,

Étape	Traitement réalisé
1. Chargement	Recherche automatique du CSV et lecture avec pandas
2. Structure	Vérification des colonnes, types et dimensions
3. Qualité	Valeurs manquantes, doublons et bornes des scores
4. Feature engineering	Score moyen = (Math + Reading + Writing) / 3
5. Catégorisation	Faible < 60 ; Moyenne 60 à < 75 ; Bonne >= 75
6. Analyse	Statistiques descriptives, comparaisons et corrélations
7. Visualisation	Histogrammes, boxplots, barplots, heatmaps

6. Contrôle qualité et préparation des données

Le contrôle qualité présenté dans le notebook donne un résultat propre sur les données fournies : 0 doublon exact, 0 valeur manquante sur les 8 variables et aucune note hors de l'intervalle 0-100. Après nettoyage, le dataset reste de taille 1 000 x 8.

Contrôle	Résultat
Nombre de lignes initiales	1 000
Colonnes	8
Doublons supprimés	0
Valeurs manquantes avant/après	0 / 0
Notes hors 0-100	0 ligne
Lignes après nettoyage	1 000

Point méthodologique

Aucune ligne n'a été supprimée uniquement en raison de l'appartenance à un groupe. Le nettoyage reste simple, traçable et reproductible.

7. Résultats descriptifs

Statistique	Mathématiques	Lecture	Écriture	Score moyen
Moyenne	66,09	69,17	68,05	67,77
Médiane	66,00	70,00	69,00	68,33
Écart-type	15,16	14,60	15,20	14,26
Minimum	0	17	10	9,00
Maximum	100	100	100	100,00






Figure 1 - Distribution des scores en mathématiques, lecture et écriture.




Figure 2 - Boxplots des scores par matière.

Lecture des résultats : la lecture affiche la moyenne la plus élevée (69,17), tandis que les mathématiques présentent la moyenne la plus faible (66,09). Les trois matières restent cependant proches, avec des distributions assez comparables et quelques valeurs faibles visibles comme observations atypiques.

8. Analyses comparatives

8.1 Préparation aux examens

Préparation	Effectif	Score moyen	Médiane	Math	Lecture	Écriture
Completed	358	72,67	73,50	69,70	73,89	74,42
None	642	65,04	65,33	64,08	66,53	64,50

L'écart de score moyen est de 7,63 points en faveur des élèves ayant terminé le cours de préparation. Dans la table croisée par catégorie, 45,0 % des élèves ayant terminé la préparation sont classés dans la catégorie Bonne, contre 25,4 % parmi ceux qui ne l'ont pas suivie. À l'inverse, la catégorie Faible représente 16,8 % des élèves ayant terminé la préparation contre 35,0 % chez ceux qui ne l'ont pas suivie.




Figure 3 - Score moyen selon la préparation aux examens.




Figure 4 - Répartition des catégories de performance selon la préparation.

8.2 Éducation des parents

Niveau d'éducation des parents	Effectif	Moyenne	Médiane
master's degree	59	73,60	73,33
bachelor's degree	118	71,92	71,17
associate's degree	222	69,57	69,67
some college	226	68,48	68,67
some high school	179	65,11	66,67
high school	196	63,10	65,00

Un gradient descriptif apparaît : la moyenne varie de 63,10 pour le groupe high school à 73,60 pour le groupe master's degree, soit 10,50 points d'écart entre les extrêmes. Cette observation doit être interprétée comme une association et non comme une causalité.




Figure 5 - Score moyen selon le niveau d'éducation des parents.

8.3 Type de repas

Type de repas	Effectif	Moyenne	Médiane
standard	645	70,84	71,33
free/reduced	355	62,20	62,67

L'écart observé est de 8,64 points. Le type de repas apparaît donc comme une variable fortement différenciée dans le dataset. Il convient toutefois d'éviter de transformer cette variable en étiquette individuelle : elle doit être utilisée comme signal contextuel parmi d'autres.




Figure 6 - Distribution du score moyen selon le type de repas.

8.4 Genre

Genre	Effectif	Moyenne	Médiane
female	518	69,57	70,33
male	482	65,84	66,33

La différence observée est de 3,73 points en faveur du groupe female dans cet échantillon. C'est un écart descriptif plus modéré que ceux observés pour la préparation, le niveau d'éducation des parents ou le type de repas.




Figure 7 - Score moyen selon le genre.

9. Corrélations entre les matières

La matrice de corrélation montre des associations positives fortes entre les trois matières : mathématiques-lecture = 0,82 ; mathématiques-écriture = 0,80 ; lecture-écriture = 0,95. Les corrélations entre chaque matière et le score moyen sont également élevées : 0,92 pour les mathématiques et 0,97 pour la lecture comme pour l'écriture.




Figure 8 - Matrice de corrélation des scores.

Précaution d'interprétation

Les corrélations avec le score moyen sont mécaniquement élevées puisque le score moyen est calculé à partir des trois notes. Elles sont utiles pour décrire la cohérence du score synthétique, mais ne doivent pas être interprétées comme une découverte indépendante.

10. Catégories de performance

Le notebook crée une variable `performance_category` à partir du score moyen : Faible si score < 60, Moyenne si $60 \leq \text{score} < 75$ et Bonne si score ≥ 75 .

Catégorie	Effectif	Part du dataset	Score moyen	Math	Lecture	Écriture
Faible	285	28,5 %	50,33	49,25	51,85	49,89
Moyenne	391	39,1 %	67,64	65,73	68,94	68,27
Bonne	324	32,4 %	83,27	81,34	84,69	83,77




Figure 9 - Nombre d'élèves par catégorie de performance.

La catégorie Moyenne est la plus représentée (39,1 %), suivie de Bonne (32,4 %) puis Faible (28,5 %). Cette segmentation est surtout utile comme outil de communication et de repérage ; elle simplifie nécessairement une distribution continue.

12. Interprétation métier

Observation	Interprétation prudente	Utilité potentielle
Préparation aux examens : +7,63 points	Association nette entre préparation et score moyen	Prioriser ou renforcer les dispositifs de préparation
Éducation des parents : écart de 10,50 points entre extrêmes	Gradient observé entre catégories d'éducation	Cibler l'accompagnement sans attribuer de causalité
Type de repas : +8,64 points pour standard	Signal contextuel associé à la performance	Identifier les besoins d'accompagnement global
Genre : +3,73 points pour female	Différence descriptive plus faible	Éviter toute règle individuelle basée sur le genre
Corrélations inter-matières fortes	Les performances scolaires sont liées entre matières	Suivre les élèves de façon multidimensionnelle

13. Recommandations opérationnelles

1. Renforcer la préparation aux examens : suivre la participation, l'assiduité et les résultats afin d'identifier les élèves pour lesquels un soutien supplémentaire est nécessaire.
2. Mettre en place un tableau de bord simple : score moyen, score par matière, catégorie de performance, participation à la préparation et évolution dans le temps.

3. Adopter une lecture multidimensionnelle : un élève ne devrait jamais être classé à partir d'un seul facteur. Les indicateurs doivent être croisés avec l'évolution des résultats et le contexte pédagogique.
4. Utiliser les variables contextuelles comme signaux d'accompagnement, pas comme étiquettes : notamment le type de repas, le genre ou le niveau d'éducation parental.
5. Créer un dispositif d'alerte humaine : les élèves du groupe Faible peuvent être proposés pour un suivi, mais la décision d'accompagnement doit rester prise par les acteurs éducatifs.

14. Limites et risques d'interprétation

- Le dataset comprend 1 000 observations mais ne permet pas, à lui seul, de conclure sur la population scolaire congolaise.
- Les analyses sont observationnelles : elles montrent des associations et ne prouvent pas de causalité.
- Le score moyen est un indicateur synthétique utile mais il masque des profils différents selon les matières.
- Les catégories Faible, Moyenne et Bonne dépendent des seuils choisis (60 et 75). Elles simplifient une variable continue.

15. Évaluation de l'atteinte des objectifs

Objectif de la proposition	État	Évidence dans le notebook
Explorer les performances scolaires	Réalisé	Statistiques descriptives, distributions, boxplots
Identifier les facteurs associés	Réalisé	Préparation, éducation parentale, repas, genre
Comparer les groupes	Réalisé	Tables et graphiques comparatifs
Visualiser les résultats	Réalisé	10 sorties graphiques visibles dans le notebook
Produire des indicateurs d'aide à la décision	Réalisé	Score moyen, catégories, tableaux synthétiques
Formuler des recommandations	Réalisé	Recommandations proposées dans le présent rapport

16. Conclusion

EduPredict montre qu'un dataset scolaire simple peut déjà produire des indicateurs utiles pour comprendre les différences de performance et structurer une démarche d'accompagnement. La préparation aux examens, le niveau d'éducation des parents, le type de repas et, dans une moindre mesure, le genre sont associés à des écarts de score moyen dans le dataset étudié. Les trois matières sont également fortement corrélées entre elles, ce qui soutient l'intérêt d'une lecture globale de la performance.

La principale conclusion méthodologique est cependant aussi importante que les résultats : ces données permettent de repérer des associations, pas de prouver des causes. Le prototype de Machine Learning illustre la possibilité d'aller vers la prédiction, mais son accuracy maximale de 44,5 % montre qu'il faut davantage de données et une validation plus robuste avant toute utilisation opérationnelle.

La prochaine étape la plus pertinente pour EduPredict serait donc de passer d'un dataset générique à des données scolaires locales, longitudinales et plus riches, tout en gardant une gouvernance centrée sur l'accompagnement humain. Le projet peut ainsi évoluer d'un exercice analytique vers un véritable outil d'aide à la décision éducative.